

Лекция 3. Проверка качества линейной регрессии

Пусть мы построили линейную регрессию. Её задача — по известным значениям признаков предсказывать значение y .

Например, если у нас один признак x , модель имеет вид

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

Если признаков несколько:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik}$$

Здесь:

- i — номер наблюдения;
- y_i — настоящее, известное значение для i -го наблюдения;
- $\hat{y}_i$ — значение, которое предсказала модель;
- x_{ij} — значение j -го признака у i -го наблюдения;
- $\hat{\beta}_0$ — свободный коэффициент модели;
- $\hat{\beta}_j$ — коэффициент при j -м признаке;
- k — количество признаков.

Знак “шляпка” $\hat{}$ означает, что величина **оценена по имеющимся данным**.

После построения модели необходимо проверить, насколько хорошо она работает.

Шаг 1. Считаем ошибки модели

Сначала для каждого наблюдения найдём остаток:

$$e_i = y_i - \hat{y}_i$$

Здесь:

- e_i — ошибка (остаток) модели для i -го наблюдения;
- y_i — настоящее значение;
- $\hat{y}_i$ — предсказанное моделью значение.

Например, если настоящее значение

$$y_i = 10,$$

а модель предсказала

$$\hat{y}_i = 8,$$

то

$$e_i = 10 - 8 = 2.$$

То есть модель ошиблась на 2 единицы.

Если

$$e_i = 0,$$

то модель точно предсказала данное наблюдение.

Шаг 2. Считаем среднюю ошибку MSE

Чтобы оценить общую ошибку модели, используется среднеквадратичная ошибка:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Здесь:

- MSE — среднеквадратичная ошибка модели;
- n — количество наблюдений;
- i — номер наблюдения;
- y_i — настоящее значение;
- $\hat{y}_i$ — предсказанное значение;
- $y_i - \hat{y}_i$ — ошибка модели;
- $(y_i - \hat{y}_i)^2$ — квадрат ошибки;
- $\sum$ означает, что мы складываем квадраты ошибок для всех наблюдений.

То есть алгоритм очень простой:

1. для каждого наблюдения находим ошибку;
2. возводим каждую ошибку в квадрат;
3. складываем квадраты;
4. делим на количество наблюдений.

Как понимать результат:

$$\text{MSE} = 0$$

означает, что модель не ошиблась ни на одном наблюдении.

Чем меньше MSE, тем в среднем точнее предсказания модели.

Однако нельзя сказать, например, что

$$\text{MSE} < 1$$

всегда означает хорошую модель.

MSE зависит от единиц измерения y .

Например, ошибка 10 рублей может быть маленькой, а ошибка 10 миллионов рублей — огромной.

Поэтому MSE нужно оценивать с учётом конкретной задачи.

Особенно важно считать MSE на **тестовых данных**, которые модель не видела во время обучения:

$$\text{MSE}_{\text{test}} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} (y_i - \hat{y}_i)^2$$

где n_{test} — количество объектов в тестовой выборке.

Шаг 3. Считаем коэффициент детерминации R^2

Следующая важная характеристика — коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Сначала найдём среднее значение y :

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

Здесь:

- R^2 — коэффициент детерминации;
- n — количество наблюдений;
- y_i — настоящее значение;
- $\hat{y}_i$ — значение, предсказанное регрессией;
- $\bar{y}$ — среднее значение всех y_i ;
- $\sum (y_i - \hat{y}_i)^2$ — сумма квадратов ошибок модели;
- $\sum (y_i - \bar{y})^2$ — общая изменчивость значений y .

Как понимать R^2 :

Например,

$$R^2 = 0.9$$

означает, что модель объясняет примерно 90% изменчивости y .

Если

$$R^2 \approx 1,$$

то модель очень хорошо описывает наблюдаемые значения.

Если

$$R^2 \approx 0,$$

то линейная регрессия практически не улучшает описание данных по сравнению с простым использованием среднего значения $\bar{y}$.

Но важно помнить:

большое $R^2 \neq$ гарантия хорошей модели.

Даже при большом R^2 у модели могут быть серьёзные проблемы. Поэтому проверку продолжаем.

Шаг 4. Проверяем, нужны ли модели отдельные признаки

Для каждого коэффициента β_j проверяем гипотезу

$$H_0 : \beta_j = 0$$

против гипотезы

$$H_1 : \beta_j \neq 0.$$

Здесь:

- H_0 — нулевая гипотеза;
- H_1 — альтернативная гипотеза;
- β_j — настоящий, неизвестный коэффициент при j -м признаке.

Гипотеза

$$H_0 : \beta_j = 0$$

означает:

“Нет достаточных оснований считать, что данный коэффициент отличается от нуля”.

Для проверки используется статистика

$$Z_j = \frac{\hat{\beta}_j}{S[\hat{\beta}_j]}$$

Здесь:

- Z_j — статистика для проверки j -го коэффициента;
- $\hat{\beta}_j$ — найденная по выборке оценка коэффициента;
- $S[\hat{\beta}_j]$ — стандартная ошибка оценки коэффициента.

Стандартная ошибка показывает, насколько неопределённой является полученная оценка $\hat{\beta}_j$.

После этого вычисляется **p -value**.

Обычно заранее выбирают уровень значимости

$$\alpha = 0.05.$$

Здесь α — заранее выбранный порог, с которым сравнивается p -value.

Если

$$p < 0.05,$$

то нулевую гипотезу отвергаем:

$$\beta_j \text{ статистически значимо отличается от } 0.$$

Если

$$p \geq 0.05,$$

то у нас недостаточно оснований отвергнуть H_0 .

Это **не означает**, что мы доказали

$$\beta_j = 0.$$

Это означает только, что имеющиеся данные не дали достаточных оснований утверждать обратное.

Шаг 5. Проверяем, значима ли модель целиком

Теперь проверяем не отдельный коэффициент, а всю регрессию сразу.

Нулевая гипотеза:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0.$$

Она означает, что все коэффициенты при признаках равны нулю.

Альтернативная гипотеза:

$$H_1 : \beta_1^2 + \beta_2^2 + \dots + \beta_k^2 > 0.$$

То есть хотя бы один коэффициент отличается от нуля.

Используется статистика

$$F = \frac{R^2/k}{(1 - R^2)/(n - k - 1)}.$$

Здесь:

- F — статистика для проверки значимости всей модели;
- R^2 — коэффициент детерминации;
- k — количество признаков;
- n — количество наблюдений;
- $n - k - 1$ — число степеней свободы для остаточной ошибки.

После вычисления F определяется p -value.

Если

$$p < 0.05,$$

то

$$H_0$$

отвергается.

Это означает, что модель в целом **статистически значима**.

Если

$$p \geq 0.05,$$

то имеющихся данных недостаточно, чтобы подтвердить статистическую значимость всей модели.

Шаг 6. Оцениваем разброс ошибок

Оценим дисперсию ошибок:

$$S_e^2 = \frac{1}{n - k - 1} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Здесь:

- S_e^2 — оценка дисперсии ошибок;
- n — количество наблюдений;
- k — количество признаков;
- $n - k - 1$ — число степеней свободы;
- y_i — настоящее значение;
- $\hat{y}_i$ — предсказанное значение;
- $y_i - \hat{y}_i$ — остаток модели.

Чтобы вернуться к исходным единицам измерения y , берём квадратный корень:

$$S_e = \sqrt{S_e^2}.$$

Здесь S_e — оценка стандартного отклонения ошибок.

Чем меньше S_e , тем меньше разброс ошибок модели.

Но, как и MSE, эту величину нужно оценивать с учётом масштаба y .

Шаг 7. Проверяем, действительно ли зависимость линейная

Линейная регрессия предполагает, что зависимость описывается линейной функцией:

$$\varphi(x) = x\beta.$$

Здесь:

- $\varphi(x)$ — функция регрессии;
- x — набор значений признаков;
- β — набор коэффициентов регрессии.

Самый простой способ проверки — построить **график остатков**.

По одной оси откладываем предсказания

$$\hat{y}_i,$$

а по другой — остатки

$$e_i = y_i - \hat{y}_i.$$

Если точки хаотично разбросаны около линии

$$e = 0,$$

то это согласуется с предположением о линейности.

Если появляется заметная форма, например дуга или кривая, то линейная модель, возможно, описывает зависимость неправильно.

Схематически:

случайное облако $\Rightarrow$ хороший признак
--

явная кривая $\Rightarrow$ возможна нелинейная зависимость.

Шаг 8. Проверяем одинаков ли разброс ошибок

Для обычной линейной регрессии предполагается

$D[\varepsilon(x)] = \sigma^2, \quad \forall x \in \mathcal{X}.$
--

Здесь:

- $\varepsilon(x)$ — случайная ошибка модели;
- $D[\varepsilon(x)]$ — дисперсия ошибки;
- σ^2 — некоторое постоянное значение дисперсии;
- $\mathcal{X}$ — множество возможных значений признаков;
- $\forall x \in \mathcal{X}$ означает “для любого возможного x ”.

Простыми словами:

разброс ошибок должен быть примерно одинаковым при разных значениях признаков и предсказаний.

Это свойство называется **гомоскедастичностью**.

Строим график

$$(\hat{y}_i, e_i).$$

Если ширина облака точек остаётся примерно одинаковой, это хороший признак.

Если получается “воронка”:

разброс ошибок увеличивается или уменьшается

то возникает подозрение на **гетероскедастичность**.

Для более строгой проверки в лекции предлагаются, например:

- тест Уайта;
- тест Бройша–Пагана;
- тест Парка;
- тест Глейзера;
- тест Голдфелда–Квандта.

Общий смысл таких тестов:

H_0 : дисперсия ошибок постоянна,

H_1 : дисперсия ошибок непостоянна.

При выбранном уровне значимости $\alpha = 0.05$:

$p < 0.05 \Rightarrow$ есть основания говорить о гетероскедастичности.

Если

$p \geq 0.05,$

то данных недостаточно, чтобы отвергнуть предположение о постоянной дисперсии ошибок.

Шаг 9. Проверяем независимость ошибок

Следующее предположение — ошибки разных наблюдений не должны систематически зависеть друг от друга.

Например, ошибка

e_i

не должна автоматически становиться большой только потому, что предыдущая ошибка

e_{i-1}

была большой.

Для графической проверки можно построить точки

$(e_{i-1}, e_i).$

Здесь:

- e_i — текущий остаток;
- e_{i-1} — предыдущий остаток.

Такой график называется **lag plot**.

Если точки образуют случайное облако, это согласуется с независимостью ошибок.

Если появляется явная закономерность, то ошибки могут быть зависимыми.

Шаг 10. Проверяем нормальность ошибок

В классической линейной регрессии предполагается

$$\varepsilon \sim N(0, \sigma^2).$$

Здесь:

- ε — случайная ошибка модели;
- $\sim$ означает “имеет распределение”;
- N — нормальное распределение;
- 0 — среднее значение ошибок;
- σ^2 — дисперсия ошибок.

То есть предполагается, что ошибки имеют примерно нормальное распределение, центрированное около нуля.

Для проверки можно построить:

- гистограмму остатков;
- normal probability plot (Q–Q plot).

На Q–Q plot:

точки примерно вдоль прямой $\Rightarrow$ распределение близко к нормальному.

Если точки сильно и систематически отклоняются от прямой, это указывает на возможное нарушение нормальности.

Шаг 11. Ищем выбросы

Выброс — наблюдение, которое находится необычно далеко от предсказания регрессии.

Сначала смотрим на остаток

$$e_i = y_i - \hat{y}_i.$$

Чем больше

$$|e_i|,$$

тем сильнее модель ошиблась на данном наблюдении.

Однако обычные остатки не всегда удобно сравнивать, поэтому используются стандартизованные остатки:

$$t_i = \frac{\hat{\varepsilon}_i}{S_e \sqrt{1 - h_i}}.$$

Здесь:

- t_i — стандартизованный остаток i -го наблюдения;
- $\hat{\varepsilon}_i$ — обычный остаток;
- S_e — оценка стандартного отклонения ошибок;
- h_i — мера того, насколько необычным является набор признаков i -го наблюдения;
- $\sqrt{1 - h_i}$ — поправка на положение наблюдения относительно остальных данных.

Чем больше

$$|t_i|,$$

тем дальше наблюдение находится от линии или поверхности регрессии.

Также в лекции для поиска проблемных наблюдений используются:

- box plot;
- расстояние Кука;
- DFBETAS;
- DFFITS.

Важно:

выброс $\neq$ обязательно влиятельное наблюдение.

Наблюдение может находиться далеко от линии регрессии, но почти не менять саму построенную модель.

И наоборот, отдельная точка может сильно менять коэффициенты регрессии. Поэтому влияние наблюдений нужно проверять отдельно.

Шаг 12. Проверяем мультиколлинеарность

Если признаков несколько, необходимо проверить, не повторяют ли они слишком сильно информацию друг друга.

Например, признаки X_1 и X_2 могут быть очень сильно линейно связаны.

Для начала можно вычислить корреляцию:

$$r_{jl} = \text{Corr}(X_j, X_l).$$

Здесь:

- r_{jl} — коэффициент корреляции между двумя признаками;
- X_j — j -й признак;
- X_l — другой, l -й признак;
- Corr — корреляция.

Коэффициент корреляции находится в пределах

$$-1 \leq r_{jl} \leq 1.$$

Если

$$r_{jl} \approx 1,$$

между признаками существует сильная положительная линейная связь.

Если

$$r_{jl} \approx -1,$$

существует сильная отрицательная линейная связь.

Если

$$r_{jl} \approx 0,$$

сильной **линейной** связи между этой парой признаков не наблюдается.

Но важно:

маленькие попарные корреляции $\nRightarrow$ мультиколлинеарности точно нет.

Мультиколлинеарность может возникать из-за зависимости сразу между несколькими признаками.

Итоговый алгоритм

После построения линейной регрессии действуем по шагам:

1. Считаем остатки:

$$e_i = y_i - \hat{y}_i.$$

2. Считаём ошибку модели:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

3. Считаём коэффициент детерминации:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}.$$

4. Проверяем статистическую значимость каждого коэффициента β_j .

5. Проверяем статистическую значимость всей модели с помощью F -теста.

6. Оцениваем разброс ошибок:

$$S_e^2 = \frac{1}{n - k - 1} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

7. Проверяем, действительно ли зависимость можно считать линейной.

8. Проверяем, одинакова ли дисперсия ошибок.

9. Проверяем независимость ошибок.

10. Проверяем нормальность ошибок.

11. Ищем выбросы и влиятельные наблюдения.

12. Проверяем мультиколлинеарность признаков.

Очень краткая памятка

