

Лекция 3. Статистическая проверка качества регрессии

В этой лекции мы изучим методы, позволяющие оценить качество регрессии. То есть оценить, насколько хорошо линия описывает данные, и подходит ли она вообще для описания данных.

Итак, пусть мы построили модель:

$$\hat{y} = b_1x_1 + \dots + b_kx_k + b_0,$$

которая описывает наши данные.

b_i — это веса. По сути, первое, что можно сделать, анализируя модель — понять, какие характеристики нам нужны, а какие нет. Если $b_i = 0$, то очевидно, что x_i для ответа модели значения не имеет.

Это называется проверкой b_i на значимость.

1) Проверка b_i на значимость

Проверяем две гипотезы:

- $H_0 : b_i = 0$
- $H_1 : b_i \neq 0$

Если примется $H_0 \rightarrow b_i = 0 \rightarrow x_i$ не важно.

Если примется $H_1 \rightarrow b_i \neq 0 \rightarrow x_i$ важно.

Алгоритм:

1. Считаем статистику:

$$t_i = \frac{b_i}{S(b_i)},$$

где $S(b_i) = \sqrt{c_{ii}}$, где c_{ii} — i -й диагональный элемент матрицы ковариации:

$$C = s_e^2(X^T X)^{-1},$$

где

$$s_e^2 = \frac{1}{n - k - 1} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

где:

- n — число наблюдений
- k — число характеристик
- X — матрица характеристик:

$$X = \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{nk} \end{pmatrix}$$

- $\hat{y}_i = b_0 + b_1x_{i1} + \dots + b_kx_{ik}$ — предсказанный ответ
- y_i — реальный ответ

2. Когда мы посчитали характеристику t_i :

- Если $t_i \in [t_{\alpha/2}; t_{1-\alpha/2}] \rightarrow H_0$ принимается $\rightarrow x_i$ не важно.
- Иначе $\rightarrow H_1$ принимается $\rightarrow x_i$ важно.

где $t_{\alpha/2}$ и $t_{1-\alpha/2}$ — это квантили распределения Стьюдента с коэффициентами $\alpha/2$ и $1 - \frac{\alpha}{2}$, а $1 - \alpha$ — это уровень доверия (обычно берут 0,95).

$t_{\alpha/2}$ и $t_{1-\alpha/2}$ находятся по таблице статистической.

2) Проверка модели на значимость

Если характеристики влияют на итоговый ответ, то модель значима, иначе незначима.

Для проверки модели на значимость проверяются гипотезы:

- $H_0 : b_1 = \dots = b_k = 0$
- $H_1 : b_1^2 + \dots + b_k^2 > 0$

Алгоритм:

1. Считается статистика:

$$F = \frac{R^2/k}{(1 - R^2)/(n - k - 1)},$$

где:

- k — число характеристик
- n — число наблюдений
- R^2 — коэффициент детерминации, который считается как:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2},$$

где:

- y_i — реальный ответ
- $\hat{y}_i$ — предсказанный ответ
- $\bar{y}$ — среднее арифметическое реальных ответов

2. После того, как посчитана статистика F :

- Если $F \leq F_{1-\alpha} \rightarrow H_0$ принимается $\rightarrow$ модель незначима.
- Если $F > F_{1-\alpha} \rightarrow H_1$ принимается $\rightarrow$ модель значима.

где $F_{1-\alpha}$ — квантиль распределения Фишера с коэффициентом $1 - \alpha$, где $1 - \alpha$ — уровень доверия (обычно берут 0,95). $F_{1-\alpha}$ ищется по таблице.

3) Анализ: лучше или хуже наша модель, чем $\bar{y}$

На этом этапе мы проверяем, описывает ли наша модель данные лучше, чем $\bar{y}$, или нет.

1. Считаем R^2 (коэффициент детерминации):

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

2. Анализ значения R^2 :

- Если $R^2 \approx 0 \implies$ наша модель (линия) почти не отличается от средней линии.
- Если $R^2 \rightarrow 1 \implies \hat{y}_i \approx y_i \implies$ предсказанные ответы почти совпадают с реальными $\rightarrow$ модель очень хорошо описывает данные.

4) Проверка того, насколько сильно характеристика x_i влияет на итоговый ответ модели y

1. Считается коэффициент корреляции:

$$r_{x,y} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sigma_x \cdot \sigma_y},$$

где:

$$\sigma_x = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}, \quad \sigma_y = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}$$

- n — число наблюдений
2. Чем больше $|r_{x_i,y}|$ по модулю, тем больше x_i влияет на ответ y .
Чем ближе $r_{x_i,y}$ к нулю, тем меньше влияния.

5) Кросс-валидация

Кросс-валидация — это процесс, который позволяет понять, как хорошо модель будет предсказывать ответы на тестовой выборке без тестовой выборки.

У кросс-валидации есть много алгоритмов, но мы изучим пока один из них.

Алгоритм LOOCV (Leave-One-Out Cross-Validation):

1. В каждом цикле берем одно наблюдение как test, остальные $n - 1$ как train.
2. В этом же цикле:
 - (a) Строим модель на нашем train.
 - (b) Считаем ошибку на test (обозначим Error_i).
3. Повторяем пункты 1, 2 для каждого наблюдения в наших данных.
4. Считаем LOOCV по формуле:

$$\text{LOOCV} = \sqrt{\frac{1}{n} \sum_{i=1}^n \text{Error}_i^2}$$

5. Оценка результатов:

- Если LOOCV — относительно маленькая ошибка $\rightarrow$ на новых тестовых данных модель работает хорошо.
- Если LOOCV — относительно большая ошибка $\rightarrow$ модель на тестовых данных работает плохо $\rightarrow$ в ней нужно что-то менять.